

# Algorytmy Przetwarzania Obrazów

## Segmentacja i analiza obrazów


WYKŁAD 4  
Dla studiów niestacjonarnych 2019/2020

Dr hab. Anna Korzyńska, prof. IBIB PAN

## Powtórzenie

## Szkielet obiektu

Intuicyjnie to punkty, do których linia ognia, podczas równomiernego spalania obiektu rozpoczętego jednocześnie z całej jego linii brzegowej, dojdzie przynajmniej z dwóch kierunków



Zbiór wszystkich punktów równoodległych od co najmniej dwóch brzegów nazywamy szkieletem



Szkielet obiektu wysegmentowanego w obrazie cyfrowym, to zbiór wszystkich punktów równoodległych od co najmniej dwóch jego brzegów.

### DEFINICJA 2.

Szkieletem zbioru  $R$  elementów obrazu cyfrowego jest zbiór wyznaczony w następujący sposób.

W zbiorze  $R$  określa się:

- potencjalnie szkieletowe (otoczone punktami obiektu) lub szkieletowe (stanowiące krzywą lub prostą ciągnącą się w dowolnym kierunku) oraz
- konturowe (w otoczeniu jest poziom jasności tła 0) elementy obrazu.

Następnie usuwa się wszystkie konturowe elementy obrazu, które nie są szkieletowymi i z tak otrzymanym zbiorem  $R$  rekurencyjnie powtarzamy procedurę aż do uzyskania zbioru zawierającego jedynie szkieletowe elementy obrazu.




Fig. 4. Wykres klasycznego algorytmu szkieletowania. Obraz cyfrowy obrazu otoczonego przez „0” i szkieletowe elementy obrazu otoczone przez „1”.

Wyznaczanie szkieletu binarnego polega na wielokrotnym stosowaniu operacji pocieniania – do momentu, aż kolejne operacje nie wpływają na wygląd obrazu wynikowego. W tym celu można stosować różne zestawy elementów strukturalnych. Przykładem adekwatnego zestawu jest 8 elementów otrzymanych w wyniku obrotów następujących elementów strukturalnych:

$$\begin{bmatrix} 0 & 0 & 0 \\ z & 1 & z \\ 1 & 1 & 1 \end{bmatrix} \text{ oraz } \begin{bmatrix} z & 0 & 0 \\ 1 & 1 & 0 \\ z & 1 & z \end{bmatrix} \text{ o kąty } 0^\circ, 90^\circ, 180^\circ \text{ i } 270^\circ.$$

### Algorytm 1 (klasyczny algorytm ścieniania):

Oznaczenia:  $I$  oznacza obraz wejściowy.  $P$  oznacza zbiór wzorców sąsiedztwa szkieletowych elementów obrazu wraz z obróconym o  $90^\circ$  pierwszym wzorcem i obróconym o  $90^\circ$ ,  $180^\circ$  i  $270^\circ$  drugim wzorcem. Znacznik  $remain$  z wartością  $true$  wskazuje, że nieskieletowe elementy obrazu mogą pozostać. Znacznik  $skel$  z wartością  $true$  wskazuje, że sąsiedztwo elementu obrazu odpowiada jednemu ze wzorców zbioru  $P$ . Jedynka/zero we wzorcu odpowiada niezerowemu/zerowemu elementowi w sąsiedztwie.

1. Podstaw  $true$  jako wartość znacznika  $remain$ .
2. **While**  $remain = true$  **do** kroki 3-12.
3. **Begin**
4. **For**  $j = 0, 2, 4$  **do** kroki 5-12.
5. **Begin**
6. **For** dla wszystkich elementów  $p$  obrazu  $I$  **do** kroki 6-10.
7. **Begin**
8. **For** dla wszystkich wzorców  $P$  **do** kroki 9.
9. **Begin**
10. **If**  $skel = true$  **then** podstaw 2 jako wartość  $p$  (szkieletowy element obrazu) **else** podstaw 3 jako wartość  $p$  (usuwany element obrazu) **do** kroku 9.
11. **For** wszystkich elementów  $p$  obrazu  $I$  **do** kroku 12.
12. **Begin**
13. **End.**

$$\begin{bmatrix} 0 & 0 & 0 \\ z & 1 & z \\ 1 & 1 & 1 \end{bmatrix}$$

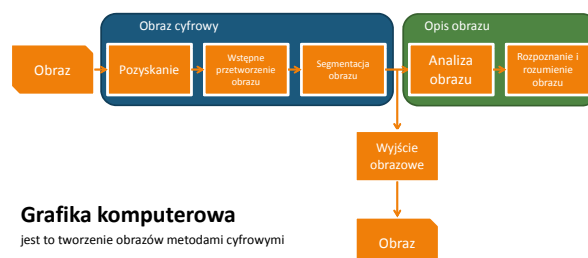
$$\begin{bmatrix} z & 0 & 0 \\ 1 & 1 & 0 \\ z & 1 & z \end{bmatrix}$$

$0^\circ, 90^\circ, 180^\circ \text{ i } 270^\circ$

13. Koniec algorytmu.

## Segmentacja i analiza obrazów to część procesu rozpoznawania obrazów

### Schemat procesu rozpoznawania obrazu



### Rozpoznawanie obrazów

Jest to proces składający się z następujących operacji:


1. **Pozyskanie** (*akwizycja*) obrazu i przetworzenie do postaci cyfrowej;
2. **Wstępne przetworzenie obrazu**, jego filtracja i wyostanie, a także jego binaryzacja;
3. **Segmentacja obrazu** i wydzielenie poszczególnych obiektów oraz ich fragmentów (np. krawędzi i innych linii);
4. **Analiza obrazu** i wyznaczenie cech obiektów oraz informacji o ich lokalizacji;
5. **Rozpoznanie** i rozumienie obrazu (identyfikacja klasy).

### Rozpoznawanie obrazów

Cel:

Wspomaganie ludzkich decyzji za pomocą informacji obrazowej lub informacji ekstrahowanej z obrazów  
Proces rozpoznawania jest **wieloletapowy**, zawiera dwa typy działań:

- ukierunkowane (detekcja dopasowania, analiza kształtu, pomiar wielkości lub odległości)
- nieukierunkowane (filtracja obrazu, zamiana na obraz monochromatyczny, wyodrębnianie krawędzi)



- Rozpoznawanie obrazów jest związane z innymi dziedzinami nauk komputerowych: uczeniem maszynowym UM, sztuczną inteligencją, komunikacją człowiek-komputer
- Zastosowania:
  - Bioidentyfikacja (oczy, uszy, odciski palców, głos)
  - Kontrola jakości produktów, kontrola samochodów na drogach (rozpoznawanie tablic rejestracyjnych), roboty i manipulatory
  - Badania przesiewowe (w diagnostyce medycznej)
  - Symulatory do nauki prowadzenia pojazdów (samolotów, pojazdów kosmicznych, samochodów wyścigowych, wieży kontrolnej lotów)
  - Marketing (Yamaha Motor)
  - Rozpoznawanie twarzy


### Metodologia rozpoznawania

- Deterministyczna (dokładna znajomość wzorców – np. liter)
- Stochastyczna (nie istnieje jednoznaczny wzorec; niejednoznaczność powoduje, że zakłada się pewien poziom błędów w klasyfikacji)
- Oparta na sieciach neuronowych
- Korelacyjna
- Lingwistyczna
- Oparte o metody Sztucznej Inteligencji

## Etapy procesu klasycznego rozpoznawania

### Faza wstępna

Ekstrakcja **cech charakterystycznych** dla danego **obiektu** w sensie celu rozpoznawania, konstrukcja klasyfikatora na podstawie obrazów za zbioru uczącego (z lub bez nauczyciela)




13

## Etapy procesu klasycznego rozpoznawania

### Faza zasadnicza

Klasyfikacja nowych obiektów/obrazów, dokonywana na podstawie tych cech



14

## Segmentacja obrazu

19

## Segmentacja

Wyodrębnienie spośród wybranych fragmentów tych, które stanowią obiekt zainteresowania ze względu na cel analizy obrazu.



Najbardziej skomplikowane algorytmy

16

## Segmentacja

- Segmentacja to podział obrazu na rozłączne (nienakładające się) fragmenty.
- Segmentacja jest powiązana z semantyką (znaczeniem i rozumieniem) obrazu. bywa rozumiana dwojako:

—Jako podział na jednorodne rejony, które składają się na znaną hierarchię lub strukturę

—Jako podział na to, co nas interesuje z punktu widzenia celu przetwarzania, pozostałe nieinteresujące obiekty i tło



7

## Cel segmentacji

Przygotowanie obrazu do etapu właściwego rozpoznawania obiektów, określenia relacji przestrzennych pomiędzy nimi.

Segmentacja stanowi poziom pośredni pomiędzy poziomem *wstępnego przetwarzania* a poziomem *analizy obrazu*.


18

## Klasyfikacja metod segmentacji


Segmentacja może być zarówno operacją kontekstową jak i niekontekstową (punktową), ale najczęściej jest kombinacją metod kontekstowych i punktowych.

Jeśli metoda:

- Ignoruje zależności między pikselami i klasyfikuje je na podstawie globalnej cechy, np. wartości poziomu szarości – progowania, to jest metodą punktową
- Wykorzystuje zależności między pikselami, np.: podobieństwo wartości poziomu szarości – „dziel i łącz”, to jest metodą kontekstową



## Segmentacja to proces wieloetapowy



## Rodzaje segmentacji

(około 1000 algorytmów segmentacji)

- Poszukiwanie nieciągłości czyli poszukiwanie krawędzi, a w konsekwencji wskazanie wnętrza obiektu (np. z wykorzystaniem histogramu dwuwymiarowego),
- Maksymalne obszary wykazujące podobieństwo w kolorze, odcieniu szarości, teksturze (progowanie, klasteryzacja, analiza tekstury, itp.)
- Wododziały (ang. *watershed transform*),
- Podziały przeszukujące obszar
- Dopasowywanie konturów np. metoda aktywnego konturu, (ang. *Active contour*)
- Metody sztucznej inteligencji oparte na głębokich sieciach neuronowych (CNN)

### Uwaga

W wyniku stosowania obszarowych metod segmentacji uzyskuje się **zawsze** obszary zamknięte (granice obszarów są ciągłe). Jest to zaleta w porównaniu np. z metodami *detekcji krawędzi*, które na ogół **nie zapewniają** ciągłości wykrytych krawędzi.

21

## Metody segmentacji obrazu

- segmentacja przez progowanie (*thresholding*) (wyznaczenie progów z histogramu poprzez znalezienie N-1 minimów pomiędzy N kolejnymi pikselami)
- segmentacja przez rozrost obszaru (*region growing algorithm*)
- segmentacja przez dołączanie (*merging algorithm*)
- segmentacja przez podział (*region splitting algorithm*)
- segmentacja przez podział i dołączanie (*split and merge algorithm*)
- segmentacja probabilistyczna (*relaxation labeling algorithm*)
- (tworzenie wektorów ufnosći pikseli określających prawdopodobieństwo, że dany piksel  $x_k$  należy do obszaru  $R_i$ )
- etykietowanie i zliczanie obiektów w obrazie (*connected component labeling*)
- segmentacja oparta na opisie tekstury
- deskrytory tekstury (*texture descriptors*); pierwsze cztery momenty centralne histogramu obrazu: wartość przeciętna (*mean*), wariancja (*variance*), miara symetrii histogramu (*skewness*), miara długości histogramu (*kurtosis*) odniesiona do jednolitości poziomu szarości obszaru; gładki histogram – niejednorodny rozkład poziomów jasności (*spiky regions*)
- histogramy różnic poziomów jasności (*histograms of gray-level differences*)
- obliczanie ciągów pikseli o takiej samej wartości (*run length statistics*)
- obliczanie wartości prawdopodobieństwa pojawienia się pary pikseli o zadanych poziomach jasności w odległości  $d$  jeden od drugiego (*co-occurrence matrix calculation*)
- charakterystyka spektralna tekstury oparta na funkcji autokorelacji (*autocorrelation function*) lub na widnie potęgowym (*power spectrum*)

## Techniki segmentacji

### Progowanie

Warunki na dobre wyniki segmentacji :

- istnieje rozdzielność poziomów szarości lub kolorów obiektu i tła
- gdy wartość minimum lokalnego w histogramie jest jak najmniejsza (ang. *valley method*)

23

## Progowanie - najprostszy algorytm segmentacji

- Progowanie z pojedynczym progiem segmentacji

$$q = \begin{cases} L_{\min} & \text{dla } p \leq p_1 \\ L_{\max} & \text{dla } p > p_1 \end{cases}$$


- Progowanie przedziałami

$$q = \begin{cases} L_{\max} & \text{dla } p_1 \leq p \leq p_2 \\ L_{\min} & \text{dla } p < p_1 \text{ lub } p > p_2 \end{cases}$$

- Progowanie z warunkiem spójności lub warunkiem nałożonym na wielkość obiektu
- Progowanie adaptacyjne
- Progowanie rekurencyjne
- Progowanie hierarchiczne (piramidowe, skalowalne)

Progowania dokonujemy na obrazie szaroodcieniowym lub pojedynczej składowej koloru lub na kanale wspólnym, np. luminancji

Operacja punktowa, bezkontekstowa

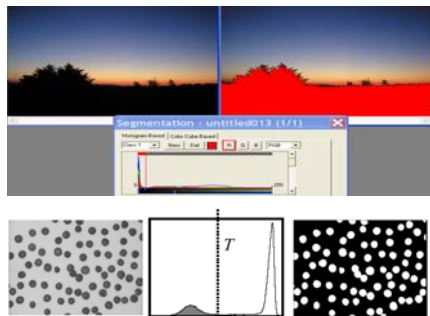


24


## Przykład progowania

Progowanie dobrze segmentuje tylko wtedy, gdy:

- istnieje rozdzielność poziomów szarości lub kolorów obiektu i tła
- gdy „dolinka” progu jest głęboka (najlepiej zerowa)

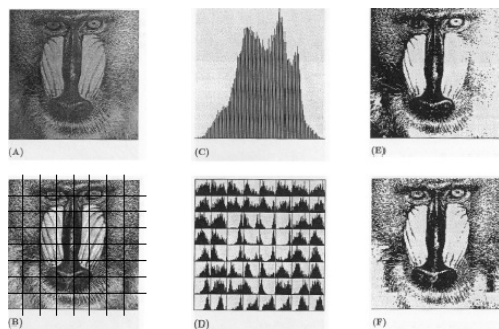


## Progowanie przedziałami



26

## Progowanie adaptacyjne



27

## Progowanie



- Zalety
  - Prosta procedura zaimplementowana w każdym oprogramowaniu do manipulacji obrazami
  - Szybka realizacja algorytmu
- Wady
  - Trudności dla obrazów o niskim kontraście
  - Trudności przy nierównomiernym oświetleniu
  - Niejednoznaczności wynikające z braku rozdzielności poziomów szarości lub kolorów, występujących w tle i obiekcie

28

## Podobieństwo tekstury

Tekstura reprezentuje, pewną relatywną jednorodność/jednolitość, odczuwaną wzrokowo przez odbiorcę lub udowodnianą jako matematyczna regularność dzięki analizie sygnału.

29




Jednorodność jest oparta na powtarzalności konstrukcyjnego elementu, wewnątrz którego istnieje pewna nierównomierność poziomów szarości (relacja między podelementami elementu konstrukcyjnego, czyli połączonymi grupami sąsiadującymi ze sobą pikseli, jest stała) lub organizację lub uporządkowanie elementów w przestrzeni.

30

## Analiza tekstury

- oparta na regularności ocenianej metodami statystycznymi, na podstawie macierzy opisującej częstotliwość występowania dwóch pikseli odległych od siebie o dystans  $d$  w kierunku  $\theta$  (po angielsku **cooccurrence matrix**), zdefiniowaną przez Haralicka  
Cechy: kierunkowość, ziarnistość, ...
- oparta na różnych zaawansowanych modelach matematycznej regularności (np. model powtarzalności/zależności poziomów szarości w różnych kierunkach obrazu, oparty na stochastycznych polach Markowa ang. **random Markov field** lub model fraktalny samopodobieństwa ang. **fractal model**)
- oparta na morfologii matematycznej, która używa różnych transformacji do porównywania struktur w obrazie do znanego elementu konstrukcyjnego tekstury

31




32

## Segmentacja oparta na statystyce

Dotyczy obrazów, dla których jednorodność obszaru nie jest mierzona jednorodnością takich **atrybutów** jak **jasność** czy **kolor**. Jednorodność obszaru mierzona jest stałym wzorcem (**tekstura**).

Segmentacja opiera się w tym przypadku na statystycznych właściwościach obszarów.



Niektóre metody:

- analiza fraktalna** tekstury oparta na **wymiarze fraktalnym  $D$**  używanym jako parametr wyróżniającym poszczególne tekstury.
- wyróżnianie (a również tworzenie) tekstur z wykorzystaniem parametrów **stochastycznych rozkładów Markowa**
- tekstura statystyczna

33

## Techniki obszarowe segmentacji

- segmentacja przez **podział obszaru** (*region splitting*)
- segmentacja przez **dołączanie obszaru** (*region merging*)
- segmentacja przez **rozrost obszaru** (*region growing*)
- segmentacja „**dziel i łącz**” (*split and merge algorithm*)

34


## Segmentacja przez podział obszaru

Procedura **iteracyjna (rekursywna)**, polega na stopniowym podziale dużych obszarów na mniejsze, w których piksele mają odpowiednią własność/cechę (kolor, jasność, teksturę), znacznie różniącą się od własności pikseli w innych obszarach. Wymaga określenia funkcji podobieństwa, a na jej podstawie „obrazu” podobieństwa oraz zastosowania metody progowania wartości funkcji **podobieństwa** obszarów, według wybranego **progu dyskryminacji**  $\Theta$ .

Dołączanie pikseli spełniających warunki progowania ich podobieństwa i będących sąsiadami jednego lub więcej pikseli należących już do obszaru (otrzymanego już w poprzednim kroku w wyniku podziału) rozszerzają obszar w kolejnych krokach.

35


Krok 1



Pseudo-objekty

Kryterium pozwalające zaliczyć znaleziony obszar do obiektu (a nie pseudo-objektu) jest oparte na wielkości obszaru.

Krok 2



- dołączenie pikseli  
- eliminacja pseudo-objektów

Kryterium: różnica pomiędzy poziomem szarości obszaru dołączanego do obiektu a poziomem szarości tego obiektu jest mniejsza od zadanego progu.

Wada:  
Duża **złożoność obliczeniowa** segmentacji przez podział.

36



### Zmniejszenie złożoności obliczeniowej

Przeprowadzenie segmentacji wstępnej na obrazie o zredukowanej rozdzielczości (przestrzennej) a następnie przeprowadzenie segmentacji dokładnej przy pełnej rozdzielczości obrazu.

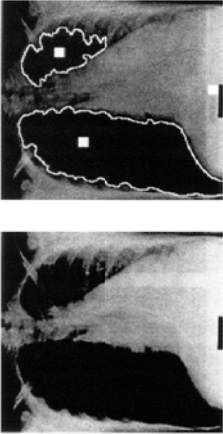
37

### Segmentacja przez rozrost obszaru

Grupowanie sąsiednich pikseli, których określona własność/cechy czyli tzn. **atrybut** (np. jasność, kolor, tekstura) mieści się w przyjętym zakresie podobieństwa. Grupy te stanowią **obszary atomowe**. Następnie testowanie sąsiadujących ze sobą obszarów atomowych pod względem ich własności i relacji przestrzennych w celu ich połączenia (scalenia).

38

### Rozrost ziarna



39

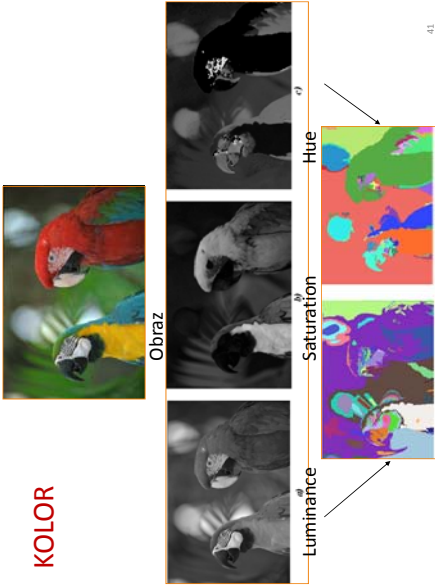
### Dziel i łącz

Zapis drzewa czwórkowy



40

### KOLOR



Obraz


Luminance

Saturation

Hue

41

### Poszukiwanie ludzi na kolorowych obrazach



Kolor skóry człowieka

Chrominancje w modelu YUV

42

## Typy krawędzi

Skok –  
stopień





Rampa



Dach




Linia



43

## Poszukiwanie krawędzi




Krawędzie





Pierwsza  
pochodna



Druga  
pochodna




laplasjan ○



44


## Krawędziowanie




Gradient w  
kierunku  
poziomym




Gradient w  
kierunku  
pionowym




laplasjan



Operator  
Sobela





Operator  
Roberts




45

## Wododział




46


## Porównanie wyników segmentacji przez wododział i operator Sobela



Obraz




Jego gradient  
operator Sobela



Wynik  
segmentacji  
przez wododział


## Snake



48




## Aktywne kontury



49

## Segmentacja według modelu




50

## Etykietowanie obiekt (indeksacja bezpośrednia)

51

## Rozróżnienie obiektów znalezionych w obrazie



52

## Indeksacja bezpośrednia obiektów po segmentacji (metoda stosu)

**1 krok:** *kasowanie* obiektu, zapamiętanie na *stosie*. Analiza kolejnych linii obrazu binarnego  $b(x,y)$ . Po napotkaniu pierwszego punktu obiektu ( $b=1$ ) następuje przeszukiwanie najbliższego otoczenia wykrytego punktu i **kasowanie** kolejnych punktów należących do tego samego obiektu. Jednocześnie **zapamiętywanie** skasowanych punktów na stosie zlokalizowanym w pamięci komputera.

**2 krok:** odtwarzanie obiektu polegające na nadaniu pikselom wartości będących kolejnymi identyfikatorami odnalezionych obiektów - automatyczne indeksowanie (do zakodowania indeksu wystarcza w praktyce 1 bajt).

53

## Etykietowanie obiektów wysegmentowanych za pomocą

- Koloru (pseudokoloru)



- Szarego odcienia



- Numeru

54

## Gdzie w materiale zgromadzonym na UBIKu znajdziemy algorytmy segmentacji


- Region growing algorithm (pp. 282-285)
- Merging algorithm (pp. 285-289)
- Region splitting algorithm (pp. 289-291)
- Split and merge algorithm (pp. 291-297)
- Relaxation labeling algorithm (pp. 297-300)
- Connected component labeling (pp. 300-303)
- Texture description (pp. 303-317)
- Subroutines for the calculation of the central moments of a histogram (pp. 303-306)
- Histograms of gray-level differences (pp. 306-308)
- Algorithm for the calculation of horizontal gray-level run lengths (pp. 308-311)
- Calculation of co-occurrence matrix (pp. 311-313)
- The spectral characterization of the image texture based on the autocorrelation function) of a two-dimensional image or on its power spectrum (pp. 313-318)

## Analiza obrazu

## Aby rozpoznać obraz potrzebna jest analiza

### Analiza prowadzi do redukcji informacji opisującej obraz do informacji istotnej z punktu widzenia celu

- Ilościowe
  - Intensywność
  - Odległość
  - Rozmiary i wielkości (pole powierzchni, obwód)
  - Rozmiar fraktalny
  - Harmoniczne
- Jakościowe
  - Istnienie wzorców/struktur i symboli
  - Lokalizacja bezwzględna lub wzajemna wzorców/struktur



57

## Charakterystyczne cechy obiektów

### Analiza kształtu

wskaźniki prezentujące niezmienność, inwariantność względem obrotów, przesunięć, zmiany skali

### Ilość obiektów (lista obiektów)


policzenie przez etykietowanie

### Pole powierzchni

zliczenie pikseli w obiekcie

### Osie i długości rzutów

Wzajemne położenia (drzewko opisu relacji przestrzennych)



58

## Analiza kształtu

### Współczynniki kształtu

Liczone na podstawie pola powierzchni  $S$  i obwodu  $L$  obiektu stanowią zgrubne przybliżenie kształtu


### Momenty geometryczne

Pozwalają na lepsze rozróżnienie obiektów niż współczynniki kształtu, ale wymagają dłuższych obliczeń

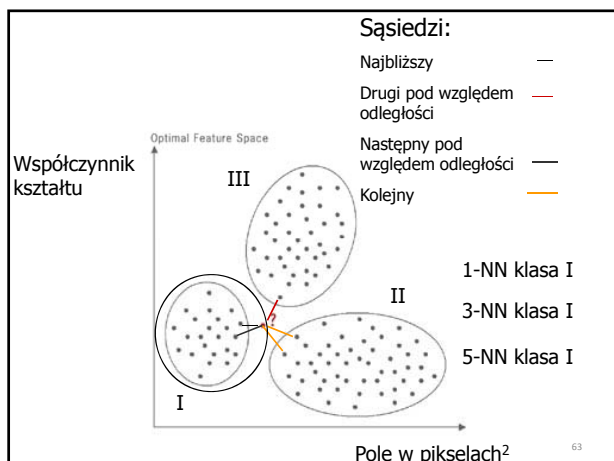


Ani współczynnik kształtu ani moment nie mogą być użyte jako jedyna miara opisująca kształt obiektów (rozpoznanie byłoby niejednoznaczne)

59

## Zastosowania metody k najbliższych sąsiadów k-NN



60



## Analiza obrazu

**Analiza obrazu – opis obrazu, wyznaczenie dla każdego obiektu *cech* przydatnych do rozpoznania**

Cechy te mogą odnosić się np. do:

- kształtu obiektu,
- liczby obiektów (zliczenie poprzez etykietowanie),
- pola powierzchni (wielkości) obiektów,
- długości osi,
- wzajemnego położenia poszczególnych obiektów.

## Analiza obrazu

realizacja odwzorowania:

$$B: D \rightarrow X$$

- $D$  - przestrzeń obrazów,
- $X$  - przestrzeń wektorów cech
- $B$  - odwzorowanie
- wyznaczenie cech obiektów (wyodrębnionych uprzednio w procesie segmentacji) przydatnych w procesie właściwego rozpoznawania; cechy charakteryzujące kształty; współczynniki *niezmiennicze* względem typowych przekształceń obrazów (obrotu, przesunięcia, zmiany skali)
- *współczynniki kształtu*,
- *momenty geometryczne*.

### Analiza obrazu

redukcja obrazu do punktu w  $n$ -wymiarowej przestrzeni cech lub do wektora cech  $\underline{x}$  w  $n$ -wymiarowej przestrzeni cech:  $\underline{x} \in X$

$x_1, \dots, x_n$  - współrzędne (składowe) wektora

## Rozpoznanie obrazu – realizacja odwzorowań

$$C: X \rightarrow R^L \quad F: R^L \rightarrow I$$


$C$  - ustalenie miary podobieństwa (*dopasowania*) nieznanego obiektu  $d \in D$  opisanego wektorem cech  $x \in X$  do jednej z klas  $L$

$F$  - ustalenie ostatecznej decyzji o przynależności obiektu  $d$  opisanego wektorem cech  $\underline{x}$  do klasy  $i \in I$  dla której miara podobieństwa jest maksymalna.

Efekt rozpoznania  
automatyczna identyfikacja klasy, do której można zaliczyć nieznaną obiekt (np. obraz).

### Wyznaczanie cech obiektów

Obraz po segmentacji:



Typowa własność cech odniesionych do kształtu obiektu:

- *afiniczność* czyli *niezmienniczość* względem:
  - obrotu.
  - przesunięcia.
  - skali.

Jakie cechy nadać obiektom 1, 2, 3, aby dokonać ich odpowiedniej klasyfikacji

Podstawowe cechy – opisujące kształt obiektu

- *współczynniki kształtu* (liczone na podstawie pola powierzchni  $S$  i obwodu  $L$  obiektu stanowią zgrubne przybliżenie kształtu)
- *momenty geometryczne* (pozwalają na lepsze rozróżnienie obiektów niż współczynniki kształtu, ale wymagają dłuższych obliczeń).

67

### Współczynniki kształtu

$$W1 = 2\sqrt{\frac{S}{\pi}}$$

**Współczynniki cyrkularności ( $W1, W2$ ):**  
 $W1$  określa średnicę koła o równej powierzchni badanego obiektu

$$W2 = \frac{L}{\pi}$$

$W2$  określa średnicę koła o długości obwodu równej długości obwodu badanego obiektu  
 $L$  - obwód obiektu,  $S$  - powierzchnia obiektu

$$W3 = \frac{L}{2\sqrt{S \cdot \pi}} - 1$$

**Współczynnik Malinowskiej**

Współczynniki  $W1, 2, 3$  - szybkie obliczanie

68

$$W4 = \frac{S}{\sqrt{2\pi \iint (r^2) ds}}$$

**Współczynnik Blaira-Blissa**  
 (większa wrażliwość na zmiany kształtu);  
 $r$  - odległość elementu pola  $ds$  od środka ciężkości obiektu

$$W5 = \frac{S^3}{\left(\iint_S ds\right)^2}$$

**Współczynnik Danielssona**  
 $l$  - minimalna odległość elementu  $ds$  od konturu obiektu

$$W6 = \sqrt{\frac{(\sum d)^2}{n \sum d^2 - 1}}$$

**Współczynnik Haralicka**  
 $d$  - odległość pikseli konturu od jego środka ciężkości  
 $n$  - liczba punktów konturu.

Współczynniki  $W4, 5, 6$  - wolniejsze obliczanie niż  $W1, 2, 3$

69

$$W7 = \frac{r_{\min}}{R_{\max}}$$

**Współczynnik  $Lp1$ :**  
 $r_{\min}$  - minimalna odległość konturu od środka ciężkości  
 $R_{\max}$  - maksymalna odległość konturu od środka ciężkości

$$W8 = \frac{L_{\max}}{L}$$

**Współczynnik  $Lp2$**   
 $W7, W8$  określają cechy pośrednie

$$W9 = \frac{2\sqrt{\pi \cdot S}}{L}$$

**Współczynnik  $Mz$**   
 (Malinowskiej uproszczony)  
 $L_{\max}$  - maksymalny gabaryt obiektu

70

### Własności współczynników kształtu $W$ :

- zbliżone wartości  $W$  dla obiektów o zbliżonym kształcie pozwalają określać stopień podobieństwa nieznanego obiektu do poszczególnych znanych klas,
- identyczne kształty - identyczne wartości  $W$ .

### Wady współczynników kształtu:

- duże zmiany skali mogą powodować, że współczynniki  $W$  dla różnych wielkości tego samego obiektu różnią się między sobą. Pojawia się wtedy możliwość błędnego zakwalifikowania do innej klasy, np. prostokąta do klasy „koło” lub odwrotnie.

### Momenty geometryczne:

Pozwalają na lepsze rozróżnienie obiektów niż współczynniki kształtu, ale wymagają dłuższych obliczeń

71

### Uwagi ogólne dotyczące algorytmów

- Dyskusja nad algorytmami obejmuje m.in. zagadnienie złożoności obliczeniowej.
- Podając algorytm próbujemy określić czas i pamięć potrzebne do jego wykonania.
- Typowy błąd: mylenie złożoności obliczeniowej i programowej.
- Generalnie, długość programu realizującego algorytm ma mało wspólnego z szybkością wykonania, a nawet z wymaganą wielkością pamięci.
- Jeśli jakaś relacja istnieje, to jest ona wręcz odwrotna.
- Algorytmy „złożone” są zwykle szybsze niż „proste”. Np. program dla FFT (nierekurencyjny) jest dłuższy i bardziej złożony niż program realizujący wzór sumy dla transformaty. Jednak wykonuje się znacznie szybciej. Podobnych przykładów dostarczają algorytmy sortowania.
- Często atrakcyjniejsze wydaje się użycie rekurencyjnej formy algorytmu, jako dużo krótszej niż nierekurencyjna, a liczba operacji w obu formach jest taka sama. W takich przypadkach należy pamiętać o kosztach wywołań rekurencyjnych, potrzebie przechowywania wartości rejestrów w pamięci itp. Jeśli liczba wywołań jest mała w porównaniu z liczbą innych operacji, to ich koszt może być opłacalny z powodu prostoty programu. W innych przypadkach algorytm w formie nierekurencyjnej daje programy wydajniejsze.
- O ile **prostota programowania** może wydawać się atrakcyjna programiście, który jest ograniczony czasem i planuje uruchomienie programu z niewielką ilością danych, o tyle jest **szkodliwa** w przypadkach zastosowań użytkowych przy dużych zbiorach danych.

### **Materiał:**

- M.Doros, Przetwarzanie obrazów, skrypt WSISIZ
- Materiały wykładowe POBZ z zeszłego roku na UBIKu
- T.Pavlidis, Grafika i Przetwarzanie Obrazów, WNT Warszawa 1987.
- I.Pitas, Digital image processing, algorithms and applications, John Wiley & Sons, Inc. 2000, pp. 162-166 (w katalogu ... \APOZ\Materialy na UBIKu).

### **Literatura dodatkowa:**

- W.Zieliński, M.Strzelecki: Komputerowa analiza obrazu biomedycznego, PWN Warszawa-Lódź 2002, str. 178-214; segmentacja z wykorzystaniem analizy tekstur, mozaika Voronoi (Voronoi tessellation), segmentacja metodą określenia działów wodnych (watershed transform)
- T.Pavlidis: Grafika i Przetwarzanie Obrazów, WNT Warszawa 1987
- R.Tadeusiewicz, P.Korohoda, Komputerowa analiza i przetwarzanie obrazów, Wydawnictwo Fundacji Postępu Telekomunikacji, Kraków 1997.  
<http://winntbg.bg.agh.edu.pl/skrypty2/0098/>
- Zasoby sieciowe.
- Segmentacja (w szczególności wododziałowa (watershed))
- <https://www.mathworks.com/company/newsletters/articles/the-watershed-transform-strategies-for-image-segmentation.html>
- Definicja tekstury:
- [http://ai.stanford.edu/~rizon/tex\\_seg/node1.html](http://ai.stanford.edu/~rizon/tex_seg/node1.html)

### **Omówienie tematów projektów**

- Materiał w katalogach na UBIKu:  
... \ APOZ \ Materialy  
... \ APOZ \ 2019-2020 \ Projekty